

RÉPUBLIQUE ALGÉRIENNE DÉMOCRATIQUE ET POPULAIRE
Ministère de L'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie HOUARI BOUMEDIENE



Spécialité : Systèmes Informatiques Intelligents

Rapport Data Mining Project : Part 1

Data Analysis and Preprocessing

Par : DELIM Mohamed Amine & NOUICER Sami Ilyas

Partie 0

Préparation des Dataset

Dans cette section, nous avons préparé les différents jeux de données nécessaires à notre projet, notamment des données climatiques mondiales et des données de sol spécifiques à l'Algérie.

0.1 Climate Algeria

L'objectif est de filtrer les informations climatiques pour ne conserver que celles pertinentes à l'Algérie. Voici les étapes suivies pour réaliser cette extraction :

1. Chargement du dataset Climate-DATA :

En utilisant la bibliothèque **xarray**, nous avons importé le dataset *Climate-DATA*, constitué de plusieurs fichiers NetCDF et qui possède les dimensions suivantes : *time* : 8760, *lat* : 360, *lon* : 720. Ce dataset contient plusieurs variables climatiques, notamment :

- **PSurf** : Pression de surface,
- **Qair** : Humidité spécifique,
- **Rainf** : Précipitations sous forme de pluie,
- **Snowf** : Précipitations sous forme de neige,
- **Tair** : Température de l'air,
- **Wind** : Vitesse du vent.

2. Extraction du polygone de l'Algérie :

À partir du fichier shapefile *Country*, qui contient plusieurs attributs, dont *FAO_NAME* et *geometry*, nous avons extrait le polygone correspondant à l'Algérie en sélectionnant l'entité avec l'attribut *FAO_NAME* = "Algeria".




FIGURE 0.1 – Polygone Algérie

3. Création du dataset climatique de l'Algérie :

Grâce à la bibliothèque **xarray** et à la fonction **rio.clip**, nous avons extrait les données climatiques spécifiques à l'Algérie. Cette opération a été réalisée en utilisant le polygone de l'Algérie comme masque spatial, permettant ainsi de fusionner les limites géographiques du pays avec les données climatiques globales pour isoler uniquement les informations pertinentes à cette région.

0.1.1 Résultat

Nous avons obtenu le dataset climatique de l’Algérie, qui présente les dimensions suivantes : *time* : 8760, *lon* : 41, *lat* : 36. Ce dataset contient uniquement les informations climatiques pertinentes pour la région de l’Algérie, après l’application du découpage spatial à l’aide du polygone de l’Algérie.




FIGURE 0.2 – Carte de la vitesse du vent à la surface de l’Algérie (5 janvier 2019)

0.2 Soil Algeria

Pour le dataset de sol de l’Algérie, nous avons remplacé toutes les valeurs égales à 0 dans les lignes où toutes les colonnes contiennent des 0 par des valeurs **NaN**. Cela a été fait, car ces valeurs de 0 indiquaient l’absence de données dans ces zones.

0.3 Climate-Soil Algeria

Après avoir obtenu nos deux dataset **climate ALGERIA** et **soil ALGERIA**, nous procédons à la fusion de ces deux dataset afin d'obtenir le dataset **Climate Soil ALGERIA** :

1. **Transformation du dataframe climat en GeoDataFrame :**

Le dataset climatique, initialement sous forme de dataframe pandas, a été converti en GeoDataFrame à l'aide de la bibliothèque **geopandas**. En utilisant les colonnes de latitude et de longitude (*lat* et *lon*), nous avons créé une nouvelle colonne *geometry* contenant des objets `Point` qui représentent les coordonnées géographiques des points climatiques. Cela permet de manipuler les données climatiques avec des opérations spatiales. Le GeoDataFrame résultant a été attribué au système de coordonnées *EPSG :4326*.

2. **Transformation du dataframe sol en GeoDataFrame :**

De même, le dataset de sol de l'Algérie, initialement sous forme de dataframe pandas, a été converti en GeoDataFrame. Après avoir appliqué cette transformation, le GeoDataFrame des sols a également été assigné au système de coordonnées *EPSG :4326*.

3. **Utilisation de `sjoin` pour la jointure spatiale :**

Une fois les deux datasets transformés en GeoDataFrames, nous avons utilisé la fonction *sjoin* de **geopandas** pour effectuer une jointure spatiale entre les données climatiques et les données de sol. La jointure a été réalisée sur la base de la géométrie, où les points climatiques (objets `Point`) ont été associés aux polygones de sol (objets `Polygon`) selon la relation spatiale *within*. Cette opération permet de fusionner les informations climatiques avec les données géographiques de sol.

0.3.1 Changement de type de données

Après la fusion, nous procédons à un changement de type des colonnes numériques. Toutes les colonnes, à l'exception de `PSurf`, sont converties en type `float16`, ce qui permet de réduire la taille des données et d'améliorer la performance lors des opérations de manipulation et de chargement des données. Le choix de ne pas modifier le type de `PSurf` est fait car cette colonne nécessite un type de données plus précis (`float32`) pour éviter toute perte d'information.


Partie 1

1.1 Manipulation des datasets

Cette section présente les différentes fonctionnalités de notre interface pour la manipulation des datasets :

1. Importation et visualisation des données :

L'interface permet l'importation de fichiers de données (climatiques ou de sol) et leur visualisation sous forme tabulaire.



The screenshot shows a web interface titled "Data manipulation". Below the title is a search bar with the text "Select a dataset" and a dropdown menu showing "climate ALGERIA". Below the search bar is a table with the following columns: time, lat, lon, PSurf, Qair, Rainf, Snowf, Tair, and Wind. The table contains 10 rows of data, each representing a time step from 2019-01-01 00:00:00 to 2019-01-01 00:00:00. The values for PSurf, Qair, Rainf, Snowf, Tair, and Wind are displayed in the corresponding columns.

	time	lat	lon	PSurf	Qair	Rainf	Snowf	Tair	Wind
37	2019-01-01 00:00:00	21.25	4.25	94,878.6484	0.0033	0	0	286.5	2.9766
38	2019-01-01 00:00:00	21.25	4.75	95,028.9063	0.0031	0	0	287.5	2.1777
39	2019-01-01 00:00:00	21.25	5.25	94,862.8125	0.0031	0	0	289.5	1.0439
40	2019-01-01 00:00:00	21.25	5.75	94,933.6797	0.0031	0	0	290	2.1055
41	2019-01-01 00:00:00	21.25	6.25	95,066.4453	0.0032	0	0	288.5	2.7871
42	2019-01-01 00:00:00	21.25	6.75	93,627.4922	0.0032	0	0	287	3.3105
43	2019-01-01 00:00:00	21.25	7.25	94,961.8516	0.0031	0	0	287	3.6934
44	2019-01-01 00:00:00	21.25	7.75	95,147.7813	0.0031	0	0	287	3.6777
45	2019-01-01 00:00:00	21.75	0.25	97,411.7109	0.0033	0	0	290.5	4.7617
46	2019-01-01 00:00:00	21.75	0.75	97,239.6797	0.0032	0	0	290.25	4.5391
47	2019-01-01 00:00:00	21.75	1.25	97,617.3573	0.0033	0	0	290.75	4.7605

FIGURE 1.1 – Tableau affichant le dataset Climate ALGERIA

2. Modification des données :

Le tableau interactif de notre interface offre également la possibilité de modifier les valeurs directement ou de supprimer des lignes.

3. Description globale du dataset :

Une fois les données chargées, notre interface fournit une description complète du dataset, incluant :

- Le nombre total de lignes et de colonnes.
- Le nombre de valeurs manquantes.
- Le type de données de chaque colonne.
- Le nombre de valeurs uniques par colonne.
- Les valeurs les plus fréquentes (*Top values*) d'une colonne et leur fréquence.




FIGURE 1.2 – Description du dataset Climate ALGERIA

4. Visualisation géographique :

Pour les datasets géospatiaux, notre interface propose des visualisations adaptées en fonction du type de données :

- **Données climatiques** : Une *heatmap* est générée en fonction de l'attribut sélectionné (par exemple, température ou vitesse du vent).




FIGURE 1.3 – Heatmap de la vitesse du vent en Algérie — 22 janvier 2019 à 00 :00

- **Données de sol** : Une carte colorée (*colormap*) est affichée, où chaque zone géographique (polygone) est colorée en fonction de la valeur de l'attribut choisi (par exemple, pH ou teneur en nutriments du sol).




FIGURE 1.4 – Carte des valeurs de pH water topsoil en Algérie

1.2 Analyse des Attributs du Dataset

1.2.1 Mesures de Tendence Centrale et Symétrie

Pour chaque attribut, les mesures suivantes sont calculées :

- **Moyenne** ($\bar{x}$) : représente la valeur moyenne des données.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (1.1)$$

- **Médiane** : valeur centrale qui divise les données en deux parties égales.

$$\text{Médiane} = \begin{cases} \text{Valeur centrale, si } n \text{ impair} \\ \frac{x_{n/2} + x_{n/2+1}}{2}, \text{ si } n \text{ pair} \end{cases} \quad (1.2)$$

-
- **Mode** : valeur la plus fréquente dans les données.

$$\text{Mode} = \text{valeur qui apparaît le plus fréquemment} \quad (1.3)$$

- **Premier quartile** ($Q1$) : valeur qui délimite le premier quart des données triées.

$$Q1 = \frac{n+1}{4} \text{ème valeur} \quad (1.4)$$

- **Troisième quartile** ($Q3$) : valeur qui délimite le troisième quart des données triées.

$$Q3 = \frac{3(n+1)}{4} \text{ème valeur} \quad (1.5)$$

Ces mesures permettent de déduire la symétrie des distributions :

- Une distribution symétrique a une moyenne égale à la médiane.
- Une asymétrie positive ou négative peut être identifiée selon l'écart entre ces mesures.

1.2.2 Mesures de Dispersion et Déduction des Valeurs Aberrantes

Les mesures de dispersion permettent d'évaluer la variabilité des données. Les principales mesures incluent l'étendue, la variance, l'écart type et l'étendue interquartile (IQR).

- **Variance** (s^2) : mesure de la déviation quadratique moyenne par rapport à la moyenne.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad (1.6)$$

- **Écart type** (s) : racine carrée de la variance, indiquant la dispersion dans les mêmes unités que les données.

$$s = \sqrt{s^2} \quad (1.7)$$

- **Étendue interquartile (IQR)** : mesure de la dispersion des 50% centraux des données.

$$\text{IQR} = Q3 - Q1 \quad (1.8)$$

Les valeurs aberrantes peuvent être identifiées par :

- **Outliers** : les valeurs situées en dehors de l'intervalle $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ sont considérées comme des valeurs aberrantes.

1.2.3 Calcul des Valeurs Manquantes et des Valeurs Uniques

Il est important de déterminer la quantité de valeurs manquantes et de valeurs uniques dans un ensemble de données pour évaluer la qualité des données.

- **Valeurs manquantes** : nombre ou pourcentage de valeurs absentes dans un attribut donné.

$$\text{Pourcentage de valeurs manquantes} = \frac{\text{Nombre de valeurs manquantes}}{\text{Nombre total d'observations}} \times 100 \quad (1.9)$$

- **Valeurs uniques** : nombre d'observations distinctes dans un attribut.

$$\text{Nombre de valeurs uniques} = \text{cardinalité de l'attribut} \quad (1.10)$$

Ces analyses aident à comprendre la qualité des données et à prendre des décisions appropriées, comme le nettoyage ou le traitement des valeurs manquantes et la gestion des doublons.

1.2.4 Construction de Boxplots et Affichage des Valeurs Aberrantes

Les boxplots (ou diagrammes en boîte) sont des graphiques utilisés pour visualiser la répartition des données et identifier les valeurs aberrantes. Un boxplot est constitué d'une boîte qui représente l'intervalle interquartile (IQR), avec des "moustaches" qui s'étendent jusqu'aux valeurs minimales et maximales, sauf si elles sont considérées comme des valeurs aberrantes.

- **Boxplot** : un graphique qui montre la médiane, le premier et le troisième quartile, ainsi que les valeurs extrêmes et aberrantes.
- **Valeurs aberrantes** : des points situés au-delà des "moustaches" du boxplot. Elles sont souvent définies comme des valeurs qui se situent en dehors de l'intervalle $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$.

Les boxplots permettent de comparer facilement la distribution de plusieurs ensembles de données et de repérer rapidement les valeurs atypiques.




FIGURE 1.5 – boîte a moustache pour l'attribut wind

1.2.5 Construction d'Histograms et Visualisation de la Distribution des Données

Les histogrammes sont des représentations graphiques de la distribution des fréquences des données. Ils sont constitués de barres qui représentent le nombre d'observations se trouvant dans chaque intervalle (ou "classe") des données.

- **Histogramme** : un graphique qui montre la fréquence de chaque intervalle de valeurs, ce qui permet d'observer la forme de la distribution (symétrique, asymétrique, etc.).
- **Distribution des données** : visualiser la distribution permet de comprendre la tendance centrale, la dispersion, et la forme générale des données (par exemple, distribution normale, biaisée, etc.).

Les histogrammes aident à identifier la densité des observations et peuvent être utilisés pour comparer différentes distributions ou identifier des modèles spécifiques (par exemple, une distribution uniforme, normale ou asymétrique).




FIGURE 1.6 – Histogramme de l'attribut Wind

1.3 Analyse des Corrélations

1.3.1 Construction et Affichage de Diagrammes de Dispersion

Les diagrammes de dispersion (ou scatter plots) sont des graphiques qui montrent la relation entre deux variables quantitatives. Chaque point sur le graphique représente une observation et sa position est déterminée par les valeurs des deux variables correspondantes.

- **Diagramme de dispersion** : un graphique où l'axe des abscisses (x) représente les valeurs d'une variable et l'axe des ordonnées (y) représente les valeurs de l'autre variable.
- **Utilité** : les scatter plots permettent de visualiser la relation entre deux variables, d'observer la tendance générale (positive, négative, ou aucune), et d'identifier d'éventuelles valeurs aberrantes.

L'analyse des diagrammes de dispersion peut révéler des corrélations entre les variables. Par exemple :

- **Corrélation positive** : lorsque les points tendent à se déplacer dans la même direction, indiquant que lorsque la valeur de la variable x augmente, celle de la variable y augmente également.
- **Corrélation négative** : lorsque les points tendent à se déplacer dans des directions opposées, indiquant qu'une augmentation de la variable x correspond à une diminution de la variable y .
- **Pas de corrélation** : lorsque les points sont dispersés sans formation de tendance apparente.

1.3.2 Calcul et Interprétation des Corrélations

Pour quantifier la relation entre deux variables, on utilise le coefficient de corrélation de Pearson, noté r , qui varie entre -1 et 1 :

- $r > 0$: corrélation positive.
- $r < 0$: corrélation négative.
- $r = 0$: aucune corrélation.

Le coefficient de corrélation de Pearson est calculé par la formule :

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1.11)$$

Cette mesure aide à comprendre la force et la direction de la relation entre les deux variables et est particulièrement utile pour la prise de décision et les modèles prédictifs.




FIGURE 1.7 – Correlation entre silt topsoil and silt subsoil

comme on peut voir dans l'exemple ci-dessus la corrélation est positive et très forte

Partie 2

2.1 Réduction des Données par Agrégation Saisonnière

2.1.1 Présentation de l'Agrégation par Saison

L'agrégation par saison est une technique qui permet de regrouper et de résumer les données en fonction de périodes saisonnières, facilitant ainsi l'analyse des tendances et des variations au fil du temps. Dans notre interface, l'utilisateur peut choisir une saison et un jour spécifique, ce qui permettra d'afficher uniquement les données correspondant à cette période précise.

2.1.2 Affichage de la Carte et de la Heatmap

Pour faciliter la visualisation et l'analyse des changements de valeurs des attributs en fonction des régions géographiques, une carte interactive est générée, accompagnée d'une heatmap. La heatmap met en évidence les zones où les attributs ont des valeurs plus élevées ou plus faibles, offrant ainsi une représentation visuelle claire des variations et des tendances géographiques.

- **Sélection de la saison et du jour** : l'utilisateur peut choisir la saison (par exemple, été, hiver, printemps, automne) et le jour spécifique pour afficher les données correspondantes.




FIGURE 2.1 – selection du jour

- **Affichage de la carte** : la carte permet de localiser les points de données sur une zone géographique précise, facilitant ainsi l'analyse régionale.




FIGURE 2.2 – Enter Caption

- **Heatmap** : la heatmap est une superposition colorée sur la carte qui montre l'intensité des valeurs des attributs par région, rendant les zones à forte ou faible concentration facilement identifiables.




FIGURE 2.3 – heatmap de l'attribut Wind

2.1.3 Utilité de l'Agrégation Saisonnière

Cette méthode de réduction des données par agrégation permet de :

- Simplifier l'analyse des données en se concentrant sur des périodes spécifiques.
- Identifier des patterns saisonniers et des tendances régionales.
- Mettre en évidence les changements de valeurs des attributs pour différentes saisons et jours, facilitant ainsi la prise de décisions et l'élaboration de modèles prédictifs.

En résumé, la fonction de réduction des données par agrégation saisonnière combinée à l'affichage de la carte et de la heatmap offre une approche efficace pour explorer et analyser les données de manière plus ciblée et compréhensible.

2.2 Gestion des outliers et des valeurs manquantes

L'interface propose plusieurs options pour traiter les valeurs manquantes et les outliers, offrant ainsi une flexibilité dans le nettoyage des données.

2.2.1 Gestion des valeurs manquantes


Pour les valeurs manquantes, plusieurs choix sont disponibles :

- **Suppression des lignes** : Supprime complètement les lignes contenant des valeurs manquantes.
- **Remplacement par la médiane ou la moyenne** : les valeurs manquantes peuvent être remplacées par la médiane ou la moyenne de la colonne.
- **Remplacement par le mode** : les valeurs manquantes peuvent être remplacées par la valeur la plus fréquente (mode).

2.2.2 Gestion des outliers


Pour la gestion des outliers, l'interface propose une option :

- **Suppression des outliers** : L'utilisateur sélectionne d'abord la colonne à traiter.



The screenshot shows a dark-themed interface titled "Outliers Handling". It contains two dropdown menus. The first dropdown is labeled "Choose a column to handle outliers:" and has "sand % topsoil" selected. The second dropdown is labeled "Choose a method for handling outliers:" and has "Delete Outliers" selected. Below these dropdowns is a button labeled "Process Outliers".

Ensuite, l'interface identifie et supprime les outliers de cette colonne. Les résultats sont visualisés à l'aide de boxplots affichant les données avant et après la suppression des outliers.



2.3 Normalisation des données

La normalisation des données est une étape essentielle pour préparer les jeux de données à l'analyse, notamment pour les algorithmes de machine learning. Notre interface propose deux méthodes de normalisation : **Min-Max** et **Z-score**.

— Méthode Min-Max :

Cette méthode transforme les valeurs de la colonne sélectionnée pour les ramener dans un intervalle spécifique, généralement compris entre 0 et 1. La formule utilisée est la suivante :

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

où X est la valeur initiale, $X_{\min}$ et $X_{\max}$ sont respectivement les valeurs minimale et maximale de la colonne.

— Méthode Z-score (Standardisation) :

Cette méthode normalise les données en les centrant autour de la moyenne avec un écart-type de 1. La formule est la suivante :

$$X_{\text{norm}} = \frac{X - \mu}{\sigma}$$

où μ est la moyenne de la colonne et σ est l'écart-type.

Fonctionnalités de l'interface :

L'interface permet de sélectionner la colonne et d'appliquer l'une des deux méthodes de normalisation.

The screenshot shows a web application interface for dataset normalization. On the left, a table displays climate data for ALGERIA. The table has columns: time, lat, lon, PSurf, Qair, Rainf, Snowf, Tair, and Wind. The data rows show values for various time points in 2019. On the right, a sidebar titled 'Dataset Normalization' contains two dropdown menus. The first dropdown, 'Choose a column:', has 'PSurf' selected. The second dropdown, 'Choose a method for normalizing values:', has 'Min-Max' selected. Below these, the 'z-score' method is also visible.

	time	lat	lon	PSurf	Qair	Rainf	Snowf	Tair	Wind
11	2019-01-01 00:00:00	20.25	3.25	93,606.4166	0.0028	0	0	287	3.1289
12	2019-01-01 00:00:00	20.25	3.75	93,625.1953	0.0028	0	0	287	3.3828
13	2019-01-01 00:00:00	20.25	4.25	95,443.9531	0.003	0	0	288	3.3535
14	2019-01-01 00:00:00	20.25	4.75	96,454.6953	0.0031	0	0	287.5	3.1465
15	2019-01-01 00:00:00	20.25	5.25	96,301.1328	0.0031	0	0	287.5	3.4395
16	2019-01-01 00:00:00	20.25	5.75	96,050.5859	0.0031	0	0	287.5	3.6523
17	2019-01-01 00:00:00	20.25	6.25	95,852.0156	0.0032	0	0	288.25	3.8125
18	2019-01-01 00:00:00	20.75	1.25	96,808.3359	0.003	0	0	290.25	4.1914
19	2019-01-01 00:00:00	20.75	1.75	96,064.8047	0.0029	0	0	289.25	3.8164
20	2019-01-01 00:00:00	20.75	2.25	95,010.7578	0.0028	0	0	287.75	3.2773
21	2019-01-01 00:00:00	20.75	2.75	95,037.0938	0.0029	0	0	287.25	2.9277

Après application, les résultats sont affichés directement dans le tableau. Par exemple, si l'on applique la méthode **Min-Max** sur la colonne **PSurf**, les valeurs de cette colonne seront transformées pour se situer entre 0 et 1.

Result									
	time	lat	lon	PSurf	Qair	Rainf	Snowf	Tair	Wind
0	2019-01-01 00:00:00	19.25	3.25	0.7011	0.0028	0	0	289.5	3.6367
1	2019-01-01 00:00:00	19.25	3.75	0.7232	0.0028	0	0	289.5	3.5332
2	2019-01-01 00:00:00	19.25	4.25	0.7175	0.0029	0	0	289.25	3.6191
3	2019-01-01 00:00:00	19.25	4.75	0.7102	0.003	0	0	289.25	3.9336
4	2019-01-01 00:00:00	19.75	3.25	0.6642	0.0028	0	0	288.5	3.3223
5	2019-01-01 00:00:00	19.75	3.75	0.6892	0.0028	0	0	288.5	3.3477
6	2019-01-01 00:00:00	19.75	4.25	0.7	0.0028	0	0	288.5	3.334
7	2019-01-01 00:00:00	19.75	4.75	0.709	0.003	0	0	288.25	3.5664
8	2019-01-01 00:00:00	19.75	5.25	0.7088	0.0031	0	0	288.5	3.959
9	2019-01-01 00:00:00	19.75	5.75	0.708	0.003	0	0	288.75	4.1758

2.4 Réduction des Données par Discrétisation des Attributs Continus : Fréquence Égale / Amplitude Égale

2.4.1 Introduction à la Discrétisation


La discrétisation des attributs continus dans un ensemble de données peut s'avérer utile pour gérer les valeurs aberrantes et lisser les données. Elle consiste à diviser les N valeurs possibles (généralement $N > 9$) d'un attribut en un nombre fini de catégories. Deux méthodes de discrétisation ont été utilisées dans notre étude : les intervalles à fréquence égale (quantiles) et les intervalles à largeur égale.

2.4.2 Méthode 1 : Discrétisation en Intervalles à Fréquence Égale (Quantiles, Fréquence Égale)

Cette méthode divise les N valeurs possibles en Q quantiles, où Q est défini par l'utilisateur. La position du i -ème quantile est calculée par la formule suivante :

$$\text{Position} = \frac{N \times i}{Q} \quad (2.1)$$

Tous les éléments qui se trouvent dans l'intervalle $[Q_i, Q_{i+1})$ sont représentés par la même catégorie, où $0 \leq i < Q$. Cette approche permet de regrouper les données de manière à ce que chaque intervalle contienne le même nombre de valeurs, facilitant ainsi la détection de tendances et la gestion des outliers.



	pH water subsoil	pH water subsoil_interval
0	0	Interval: (-0.001, 3.59]
1	7.8008	Interval: (7.784, 7.851]
2	3.5996	Interval: (3.59, 3.73]
3	3.5742	Interval: (-0.001, 3.59]
4	7.1992	Interval: (7.197, 7.314]
5	8.0625	Interval: (8.061, 8.145]
6	3.7246	Interval: (3.59, 3.73]
7	7.7305	Interval: (7.703, 7.784]
8	3.75	Interval: (3.73, 4.775]
9	7.5391	Interval: (7.489, 7.603]

FIGURE 2.4 – discrétisation par quantiles

2.4.3 Méthode 2 : Discrétisation en Intervalles à Largeur Égale

Cette méthode consiste à définir ou calculer le nombre d'intervalles, k , à utiliser. Le nombre optimal d'intervalles est déterminé par la formule suivante :

$$k = 1 + \frac{10}{3} \log_{10}(n) \quad (2.2)$$

où n est le nombre total d'observations dans l'ensemble de données.

La largeur de chaque intervalle est calculée comme suit :

$$\text{Largeur de l'intervalle} = \frac{\text{Valeur maximale} - \text{Valeur minimale}}{k} \quad (2.3)$$

Tous les éléments qui se trouvent dans le même intervalle sont représentés par la même catégorie. Cette approche permet de segmenter les données en intervalles de largeur uniforme, facilitant ainsi l'analyse de la distribution des valeurs.

	clay % topsoil	clay % topsoil_interval
0	0	Interval: (-0.0603, 2.621]
1	24.7969	Interval: (23.588, 26.209]
2	24.7969	Interval: (23.588, 26.209]
3	12.4531	Interval: (10.484, 13.105]
4	12.4531	Interval: (10.484, 13.105]
5	24.7969	Interval: (23.588, 26.209]
6	12.4531	Interval: (10.484, 13.105]
7	12.4531	Interval: (10.484, 13.105]
8	12.4531	Interval: (10.484, 13.105]
9	12.375	Interval: (10.484, 13.105]

FIGURE 2.5 – Enter Caption

2.4.4 Utilité de la Discrétisation

La discrétisation des données permet de :

- Réduire la complexité des données continues en les regroupant en catégories distinctes.
- Améliorer la gestion des valeurs aberrantes en les attribuant à des catégories spécifiques.
- Lissage des données pour une meilleure visualisation et analyse.
- Préparer les données pour des algorithmes de modélisation qui nécessitent des entrées discrètes.

Ces méthodes de discrétisation offrent des solutions flexibles pour la gestion des attributs continus et permettent une meilleure exploration et analyse des ensembles de données en facilitant la détection des motifs et des relations.

2.5 Réduction des données (élimination des redondances) : Horizontal / Vertical

La réduction des données est une étape essentielle pour améliorer l'efficacité de l'analyse et réduire la complexité des datasets. Notre interface permet de gérer la réduction des données à deux niveaux : horizontal et vertical, et donne à l'utilisateur la possibilité de choisir entre ces deux options, ou bien de les appliquer simultanément.

2.5.1 Réduction horizontale

La réduction horizontale consiste à éliminer les lignes redondantes du dataset, c'est-à-dire les lignes qui contiennent des valeurs identiques.

2.5.2 Réduction verticale

La réduction verticale consiste à supprimer les colonnes contenant des valeurs identiques ou redondantes, afin d'optimiser la taille du dataset en ne conservant que les colonnes pertinentes.